Лабораторная работа 2. Обучение без учителя. Понижение размерности. Обнаружение аномалий. Кластеризация.

1. Требуется проанализировать входные данные и выполнить отбор признаков – выделить главные признаки, оценить их влияние на распределение данных, выделить второстепенные и малозначимые признаки, определить шумовые компоненты (при наличии). Для выполнения задания можно использовать библиотеки SciPy и scikit-learn, и любые вспомогательные библиотеки.

Датасет **Lab2_Dataset_PCA.xlsx** включает в себя набор из 5 признаков (по вариантам) и столбец корректных меток ***y*** для проверки. Столбец корректных меток ***y*** **не должен** использоваться в анализе и служит только для визуализации результатов.

1.1 Рассчитать матрицу взаимных корреляций между признаками.

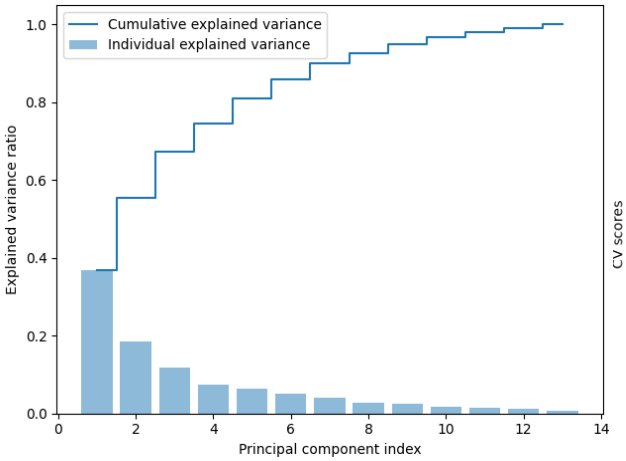
1.2 Построить матрицу разброса признаков с помощью pd.plotting.scatter_matrix() или аналогичных функций.

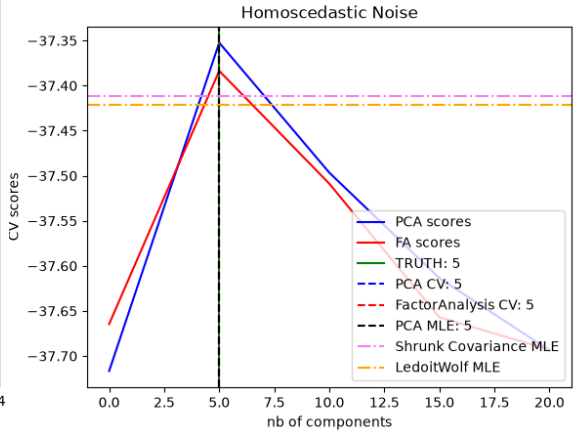
1.3. Оценить значимость признаков и зашумлённость данных используя:

1. Анализ главных компонент (PCA)
2. Сингулярное разложение (SVD)
3. Анализ независимых компонент (ICA)

1.4. Определить перечень наиболее значимых компонент, второстепенных компонент, шумовых компонент(при наличии) для каждого из методов. Построить графики значимости компонент на основе объяснённой дисперсии или правдоподобия (score).

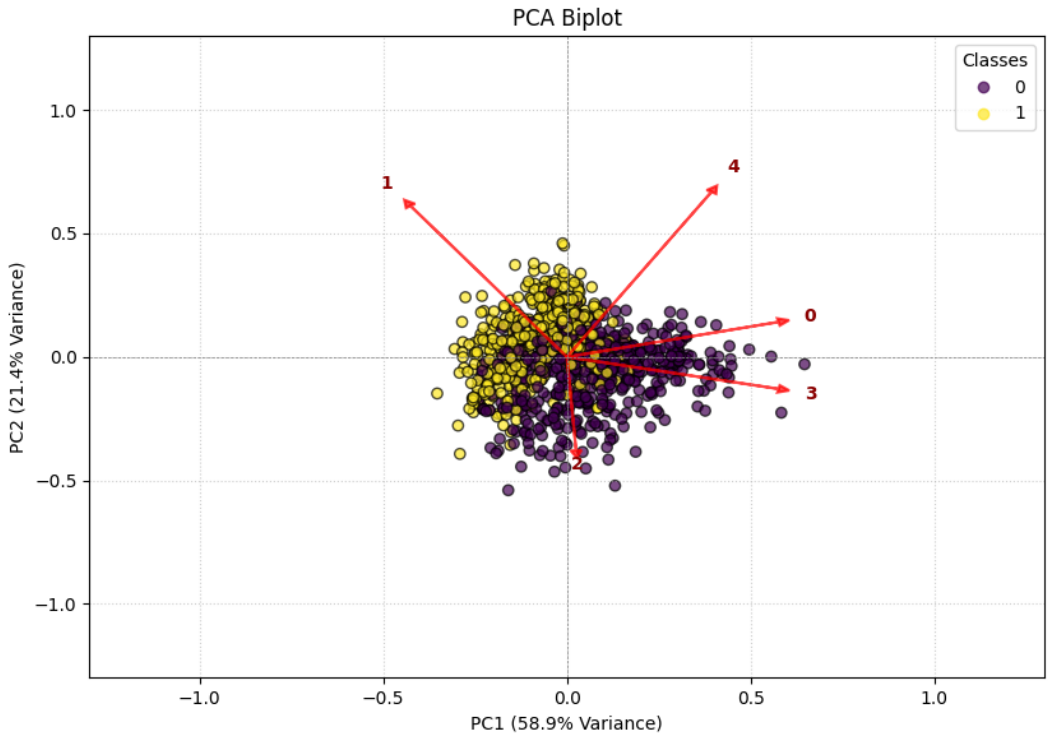
Примеры графиков:





1.5. Построить scatter-графики проекций распределения данных на двумерное пространство с использованием 2 наиболее значимых компонент для каждого из методов, отобразив на графиках главные направления каждой из компонент на основе правдоподобия (score).

Пример графика:



Пример кода для построения данного графика:

```
def biplot(loadings, labels=None, targets=None, target_labels=None):
    fig, ax = plt.subplots(figsize=(9, 7))

    # Scale components for better visual overlay alignment
    # Scores can be large, while loadings are bounded between -1 and 1
    scalex = 1.0 / (scores[:, 0].max() - scores[:, 0].min())
    scaley = 1.0 / (scores[:, 1].max() - scores[:, 1].min())

    # Plot the data points (Scores)
    if targets is not None:
        scatter = ax.scatter(scores[:, 0] * scalex, scores[:, 1] * scaley, c=targets, cmap='viridis',
alpha=0.7, edgecolors='k')
        handles, _ = scatter.legend_elements()
        ax.legend(handles, target_labels, title="Classes")
    else:
        ax.scatter(scores[:, 0] * scalex, scores[:, 1] * scaley, alpha=0.7)

    # Plot the feature vectors (Loadings)
    n_features = loadings.shape[0]
    for i in range(n_features):
        # Draw red arrows from the origin
        ax.arrow(0, 0, loadings[i, 0], loadings[i, 1], color='r', alpha=0.7,
                 head_width=0.03, head_length=0.03, linewidth=1.5)

        # Place text labels at the tip of the arrows
        if labels is not None:
            # Slight offset so text doesn't overlap arrow tip perfectly
            ax.text(loadings[i, 0] * 1.15, loadings[i, 1] * 1.15, labels[i],
```

```
                color='darkred', ha='center', va='center', fontweight='bold')

    # Grid and axis formatting
    ax.axhline(0, color='gray', linestyle='--', linewidth=0.5)
    ax.axvline(0, color='gray', linestyle='--', linewidth=0.5)
    ax.set_xlabel(f"PC1 ({pca.explained_variance_ratio_[0]*100:.1f}% Variance)")
    ax.set_ylabel(f"PC2 ({pca.explained_variance_ratio_[1]*100:.1f}% Variance)")
    ax.set_title("PCA Biplot")
    ax.grid(True, linestyle=':', alpha=0.6)

    # Pad layout limits slightly beyond the vectors (-1 to 1)
    ax.set_xlim(-1.3, 1.3)
    ax.set_ylim(-1.3, 1.3)

    plt.tight_layout()
    plt.show()

#feature_names названия столбцов, необязательны
#Yp – массив корректных метки
#target_labels – имена классов
scores = pca.fit_transform(X_scaled) #применить PCA и сохранить scores
loadings = pca.components_.T # Shape: (n_features, n_components)
biplot(scores, loadings, labels=feature_names, targets=Yp, target_labels=[0,1,2,3])
```

2. Требуется выделить кластеры в исходных данных с помощью перечня алгоритмов кластеризации, реализованных в библиотеке scikit-learn:

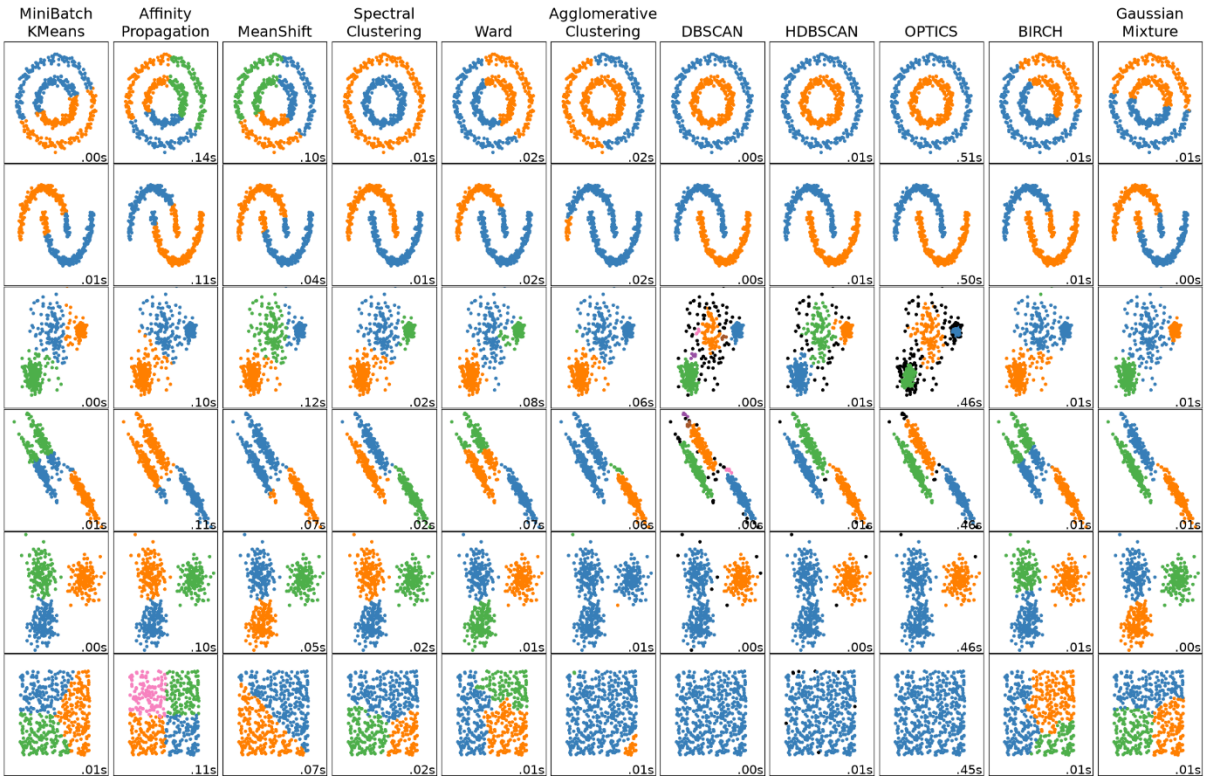
1. K-Means
2. Affinity propagation
3. Mean-shift
4. Spectral clustering
5. Ward hierarchical clustering
6. Agglomerative clustering
7. DBSCAN
8. HDBSCAN
9. OPTICS
10. Gaussian mixtures
11. BIRCH
12. Bisecting K-Means

Датасет **Lab2_Dataset_Clustering.xlsx** включает в себя 2 признака (по вариантам) и столбец корректных меток ***y*** для проверки. Столбец корректных меток ***y* не должен** использоваться в анализе и служит только для визуализации результатов. Разрешается использовать любые вспомогательные библиотеки.

2.1. Определить алгоритмы кластеризации из перечня, позволяющие выполнить разделение кластеров на основе пространственного распределения, связности и формы кластеров. Определить алгоритмы, не позволяющие решить задачу. Обосновать.

2.2. Построить графики результатов для каждого алгоритма (как работоспособных, так и неработоспособных) на одном общем графике, используя plt.subplots().

Пример графика:

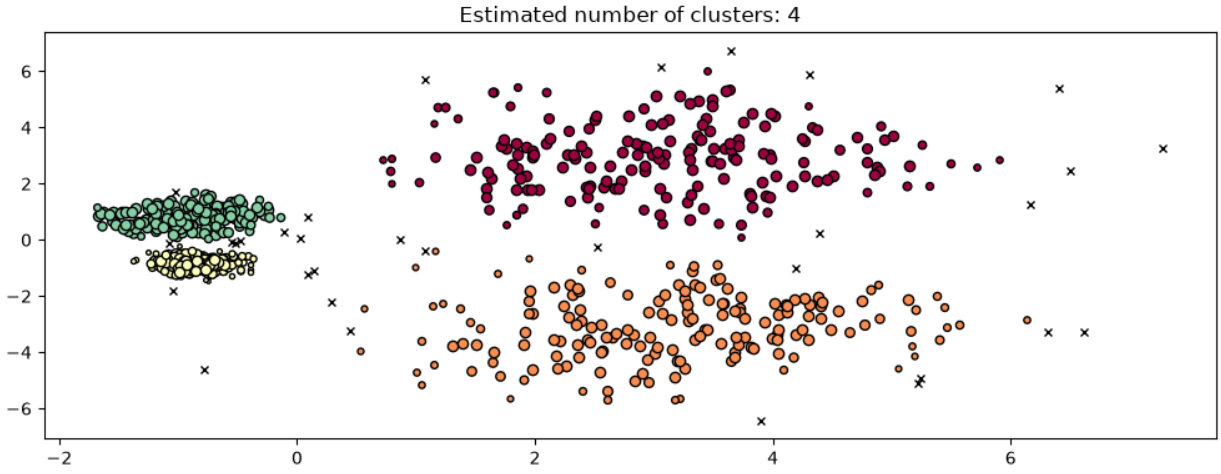


2.3. Подобрать параметры для выбранных методов, обеспечивающие как можно более чёткое разделение кластеров. Для методов на основе плотности DBSCAN, HDBSCAN, OPTICS проанализировать эффективность отделения выбросов (outliers). Объяснить результаты.

2.4. Выделить аномальные данные (при наличии) в датасете, обнаруженные методами кластеризации, построить график, выделив цветом каждый кластер, включая кластер аномальных данных, используя scatter-график.

Пример графика:





2.5. Сравнить результаты с эталонными и обосновать выбор наиболее эффективного для данного датасета алгоритма кластеризации.